



Norges teknisk-naturvitenskapelige universitet
Institutt for matematiske fag

SIF 5060 Statistikk

Løsningsforslag - Eksamen nov. 2002

Oppgave 1

a)

Vi har tre jordskjelvtyper, K , M og S , som har forskjellige sannsynlighetsfordelinger for skaden D de påfører en bygning.

Bruker her x som integrasjonsvariabel over mulige verdier for D .

$$P(D > 1.0|K) = \int_1^\infty \lambda_K e^{-\lambda_K x} dx = e^{-\lambda_K} = e^{-1.61} = 0.2.$$

For de andre jordskjelvtypene blir integralet tilsvarende, og vi får:

$$P(D > 1.0|M) = e^{-\lambda_M} = e^{-3.0} = 0.05$$

$$P(D > 1.0|S) = e^{-\lambda_S} = e^{-4.6} = 0.01$$

b)

De tre jordskjelvtypene er distinkte og har forskjellig oppførsel, altså må området $D > 1.0$ undersøkes separat for de tre tilfellene. (Tegn gjerne et Venn-diagram.) Bruker loven om total sannsynlighet for å evaluere den totale sannsynligheten for skade.

$$\begin{aligned} P(D > 1.0) &= P(D > 1.0 \cap K) + P(D > 1.0 \cap M) + P(D > 1.0 \cap S) \\ &= P(D > 1.0|K)P(K) + P(D > 1.0|M)P(M) + P(D > 1.0|S)P(S) \\ &= 0.2 \cdot 0.02 + 0.05 \cdot 0.20 + 0.01 \cdot 0.78 = 0.0218. \end{aligned}$$

Merk at det selvfølgelig er forutsatt at det faktisk har inntruffet et jordskjelv.

Det neste spørsmålet er; gitt at vi ser at bygningen har falt sammen pga et jordskjelv (som ikke er observert), hva er sannsynligheten for at det ukjente jordskjelvet var av middels styrke? Poenget er å skrive om uttrykket for betinget sannsynlighet slik at bare kjente størrelser inngår.

$$\begin{aligned} P(M|D > 1.0) &= \frac{P(D > 1.0 \cap M)}{P(D > 1.0)} = \frac{P(D > 1.0|M)P(M)}{P(D > 1.0)} \\ &= \frac{0.05 \cdot 0.20}{0.0218} = 0.459. \end{aligned}$$

c)

Definerer hendelsene A : bygning A svikter, B : bygning B svikter.

$$\begin{aligned}
 P(A \cap B) &= P(A \cap B \cap K) + P(A \cap B \cap M) + P(A \cap B \cap S) \\
 &= P(B|A \cap K)P(A|K)P(K) + P(B|A \cap M)P(A|M)P(M) + P(B|A \cap S)P(A|S)P(S) \\
 &= 0.5 \cdot 0.2 \cdot 0.02 + 0.15 \cdot 0.05 \cdot 0.2 + 0.02 \cdot 0.01 \cdot 0.78 \\
 &= 0.002 + 0.0015 + 0.000156 = 0.0037
 \end{aligned}$$

$$\begin{aligned}
 P(K'|A \cap B') &= 1 - P(K|A \cap B') \\
 P(K|A \cap B') &= \frac{P(A \cap B' \cap K)}{P(A \cap B')} = \frac{P(B'|A \cap K)P(A \cap K)}{P(A) - P(A \cap B)} \\
 &= \frac{(1 - P(B|A \cap K))P(A \cap K)}{P(A) - P(A \cap B)} \\
 &= \frac{0.5 \cdot 0.2 \cdot 0.02}{0.0218 - 0.0037} = \frac{0.002}{0.0181} = 0.11 \\
 P(K'|A \cap B') &= 1 - 0.11 = 0.89
 \end{aligned}$$

Oppgave 2

a)

X = absolutt styrke av vilårlig valgt jordskjelv. Har at $X \sim N(x; 4.2, 0.4)$. Har

$$\begin{aligned}
 P(X > 5.4) &= P\left(\frac{X - 4.2}{0.4} > \frac{5.4 - 4.2}{0.4}\right) \\
 &= 1 - \Phi(3) \\
 &= 1 - 0.9987 \\
 &= 0.0013.
 \end{aligned}$$

Kaller vår grenseverdi k . Da er

$$\begin{aligned}
 P(X > k) &= 0.05 \\
 &\Downarrow \\
 P\left(\frac{X - 4.2}{0.4} > \frac{k - 4.2}{0.4}\right) &= 0.05 \\
 &\Downarrow \\
 \frac{k - 4.2}{0.4} &= 1.645 \\
 &\Downarrow \\
 k &= 4.2 + 1.645 \cdot 0.4 \\
 &= 4.858 \\
 &\approx 4.9.
 \end{aligned}$$

b)

Vi har følgende hypotese:

$$H_0 : \mu = 4.2$$

$$H_1 : \mu > 4.2.$$

Under H_0 er $\frac{\bar{X}-4.2}{\frac{s}{\sqrt{9}}} \sim t$ -fordelt med 8 frihetsgrader. Forkast dersom $\frac{\bar{X}-4.2}{\frac{s}{\sqrt{9}}} \geq t_{0.05,8} = 1.86$.
Setter vi inn får vi $\frac{3.967-4.2}{\frac{s}{\sqrt{9}}} = -1.07 < 1.86$. Konklusjonen blir at man ikke forkaster hypotesen.

c)

X = antall jordskjelv i et tidsrom $[0, t]$, der t er gitt i år. $t = 1$. Da er

$$\begin{aligned} P(X = 8 | \lambda = 5) &= \frac{(5 \cdot 1)^8}{8!} \cdot \exp(-5 \cdot 1) \\ &= 0.0653. \end{aligned}$$

$t = 0.5$. Da er $\lambda t = 2.5$, og

$$\begin{aligned} P(X \geq 5 | \lambda t = 2.5) &= 1 - P(X \leq 4 | \lambda t = 2.5) \\ &= 1 - 0.8912 \\ &= 0.1088. \end{aligned}$$

Ser på ekstremverdiene. Har da

$$\begin{aligned} P((\max X_i)_{i=1,2,\dots,10} > 10) &= 1 - P((\max X_i)_{i=1,2,\dots,10} \leq 10) \\ &= 1 - P(X_i \leq 10)^{10} \\ &= 1 - 0.9863^{10} \\ &= 1 - 0.871 \\ &= 0.129. \end{aligned}$$

d)

T = tid det tar fra å registrere et jordskjelv til første jordskjelv intreffer.

$$\begin{aligned}
P(T > t) &= \begin{cases} P(X = 0) & \text{i intervallet } [0, t] \\ 1 & \end{cases}, t > 0 \\
&= \begin{cases} \frac{(\lambda t)^0 \cdot \exp(-\lambda t)}{0!} & \text{i intervallet } [0, t] \\ 1 & \end{cases}, t > 0 \\
&= \begin{cases} \exp(-\lambda t) & \text{i intervallet } [0, t] \\ 1 & \end{cases}, t > 0 \\
&\Downarrow \\
F_T(t) &= P(T \leq t) \\
&= 1 - P(T > t) \\
&= \begin{cases} 1 - \exp(-\lambda t) & , t \geq 0 \\ 0 & , t < 0. \end{cases} \\
&\Downarrow \\
f(t) &= \frac{dF_T(t)}{dt} \\
&= \begin{cases} \lambda \exp(-\lambda t) & , t \geq 0 \\ 0 & , t < 0. \end{cases}
\end{aligned}$$

Ser da at T er eksponensialfordelt med parameter $\frac{1}{\lambda}$.
La $X = 2\lambda T$. Har da

$$\begin{aligned}
P(X \leq x) &= P(2\lambda T \leq x) \\
&= P(T \leq \frac{x}{2\lambda}) \\
&= 1 - \exp(-\frac{x}{2}), x \geq 0 \\
&\Downarrow \\
f_X(x) &= \frac{1}{2} \exp(-\frac{x}{2}), x \geq 0.
\end{aligned}$$

For $n=2$ får vi for tettheten i kjikvadratfordelinga

$$\begin{aligned}
f_Y(y) &= \frac{1}{2^{\frac{2}{2}} \Gamma(\frac{2}{2})} y^{\frac{2}{2}-1} \exp(-\frac{y}{2}) & , y \geq 0 \\
&= \frac{1}{2} \exp(-\frac{y}{2}) & , y \geq 0.
\end{aligned}$$

e)

Har $f_T(t) = \lambda \exp(-\lambda t), t \geq 0$. Lager en sannsynlighetsmaksimeringsfunksjon

$$\begin{aligned} L(t_1, \dots, t_n; \lambda) &= \prod_{i=1}^n \lambda \exp(-\lambda t_i) \\ &= \lambda^n \exp(-\lambda \sum_{i=1}^n t_i) \\ \ln(L(t_1, \dots, t_n; \lambda)) &= n \ln(\lambda) - \lambda \sum_{i=1}^n t_i \\ \frac{d \ln(L)}{d \lambda} &= \frac{n}{\lambda} - \sum_{i=1}^n t_i. \end{aligned}$$

Setter $d \ln(L)/d \lambda = 0$. Får da

$$\begin{aligned} \lambda &= \frac{n}{\sum_{i=1}^n t_i} \\ &= \frac{1}{\bar{t}}. \end{aligned}$$

For $\lambda = \hat{\lambda}$;

$$\hat{\lambda} = \frac{1}{\bar{T}}.$$

Ser på $2\lambda n/\hat{\lambda}$. Vi har

$$\begin{aligned} \frac{2\lambda n}{\hat{\lambda}} &= \frac{2\lambda n}{\frac{n}{\sum_{i=1}^n T_i}} \\ &= 2\lambda \sum_{i=1}^n T_i, \end{aligned}$$

som er en χ^2 -fordelt med $2n$ frihetsgrader (summen av n uavhengige χ^2 -fordelte variable, hver med 2 frihetsgrader). Vi får

$$\begin{aligned} P(\chi_{0.975, 2n}^2 < 2\lambda \sum_{i=1}^n T_i < \chi_{0.025, 2n}^2) &= 0.95 \\ P\left(\frac{\chi_{0.975, 2n}^2}{2 \sum_{i=1}^n T_i} < \lambda < \frac{\chi_{0.025, 2n}^2}{2 \sum_{i=1}^n T_i}\right) &= 0.95. \end{aligned}$$

For $n = 10$ og $\bar{t} = 1/4$, får vi $2 \sum_{i=1}^n t_i = 2 \cdot 10 \cdot \frac{1}{4} = 5$, og intervallet blir $(\frac{9.591}{5}, \frac{34.17}{5}) = (1.92, 6.83)$.

Et konfidensintervall inneholder alle H_0 -hypoteser som ikke blir forkasta i tosidig test, slik at vi ikke kan konkludere med at $\lambda \neq 5$ på 5% nivå. Har relativt god margin, slik at det er lite grunnlag for å konkludere med at $\lambda \neq 5$.

Oppgave 3

Modellen til laboratoriet er $Y = \alpha + \beta x + \epsilon$, hvor ϵ og dermed også Y er stokastiske variable, mens x er en variabel som laboranten har kontroll på. Parametrene α og β er ukjente og skal estimeres.

Minste kvadratsumsestimatorene A og B for hhv. α og β er

$$A = \frac{1}{n} \sum_{i=1}^n Y_i - B\bar{x} = \bar{Y} - B\bar{x}$$

$$B = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

a)

For å vise at estimatorene er forventningsrette, undersøker vi forventningsverdien;

$$\begin{aligned} E[B] &= \frac{\sum_{i=1}^n (x_i - \bar{x})(\alpha + \beta x_i)}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\alpha \sum_{i=1}^n (x_i - \bar{x}) + \beta \sum_{i=1}^n (x_i - \bar{x})x_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (1) \\ &= \frac{\beta \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta. \\ E[A] &= \frac{1}{n} \sum_{i=1}^n (\alpha + \beta x_i) - \beta \bar{x} = \alpha + \beta \bar{x} - \beta \bar{x} = \alpha. \\ \text{Var}[B] &= \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}[Y_i]}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} = \frac{\sigma^2 \sum_{i=1}^n (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \\ &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \\ \text{Var}[A] &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}[Y_i] + \text{Var}[B]\bar{x}^2 \\ &= \frac{\sigma^2}{n} + \frac{\bar{x}^2 \sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] \\ &= \frac{\frac{\sigma^2}{n} \sum_{i=1}^n x_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned}$$

I beregningene har vi benyttet at $\sum_{i=1}^n (x_i - \bar{x}) = (\sum_{i=1}^n x_i) - n\bar{x} = 0$. Denne summen kan trekkes fra og legges til for å få uttrykket enklest mulig. (Dette kan kreve litt erfaring.) Alternativt kan en gjøre beregningen mer detaljert ved å utvide kvadratene

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2,$$

og deretter forkorte der det er mulig. I beregningen av variansen til A har vi brukt opplysningen om at kovariansen mellom \bar{Y} og B er null, ellers måtte kovariansen trekkes fra i uttrykket.

Både A og B blir normalfordelte, da de er lineærkombinasjoner av normalfordelte variable.

b)

Her undersøkes variansen til $Y_0 - \hat{Y}_0$, for $\hat{Y}_0 = A + Bx_0 = \bar{Y} - B\bar{x} + Bx_0$.

$$\begin{aligned}
 \text{Var}[Y_0 - \hat{Y}_0] &= \text{Var}[Y_0] + \text{Var}[\hat{Y}_0] \\
 &= \sigma^2 + \text{Var}[A + Bx_0] = \sigma^2 + \text{Var}[\bar{Y} - B\bar{x} + Bx_0] \\
 &= \text{Var}[\bar{Y}] + \text{Var}[B](x_0 - \bar{x})^2 + \sigma^2 \\
 &= \sigma^2 \left\{ 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\} \\
 &= \sigma^2 \left\{ 1 + \frac{1}{10} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_{i=1}^{10} - \bar{x})^2} \right\}.
 \end{aligned}$$

Dette uttrykket er minimert for $\bar{x} = x_0$, som gir at serie 1 bør brukes selv om serie 2 gir minst varians for B . (Se uttrykket for variansen til B i oppgave a.) Variansen til A blir den samme for de to måleseriene.