



LØSNINGSFORSLAG TIL EKSAMEN I FAG TMA4240/TMA4245 STATISTIKK  
10. august 2005

**Oppgave 1 Smeltepunktsbestemmelse**

- a) Vi jobber i dette punktet med uavhengige og identisk fordelte stokastiske variabler fra en normalfordeling med forventningsverdi  $\mu = 1468^\circ\text{C}$  og standardavvik  $\sigma = 2^\circ\text{C}$ .

La  $X$  være en slik normalfordelt stokastisk variabel, og la  $Z$  være en standard normalfordelt stokastisk variabel:

$$\begin{aligned} P(X < 1467) &= P\left(\frac{X - 1468}{2} \leq \frac{1467 - 1468}{2}\right) \\ &= P\left(Z \leq -\frac{1}{2}\right) = \Phi\left(-\frac{1}{2}\right) = \underline{\underline{0.3085}} \end{aligned}$$

Anta så at metallurgen tar åtte uavhengige målinger av smeltepunktet,  $X_1, X_2, \dots, X_8$ .

Da er gjennomsnittet,  $\bar{X} = \frac{1}{8} \sum_{i=1}^8 X_i$ , også en normalfordelt stokastisk variabel (siden det er en linearkombinasjon av uavhengige og normalfordelte stokastiske variabler), med forventning og varians:

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{1}{8} \sum_{i=1}^8 X_i\right) = \frac{1}{8} \sum_{i=1}^8 E(X_i) = \frac{1}{8} \sum_{i=1}^8 \mu = \mu = 1468 \\ \text{Var}(\bar{X}) &= \text{Var}\left(\frac{1}{8} \sum_{i=1}^8 X_i\right) = \frac{1}{8^2} \sum_{i=1}^8 \text{Var}(X_i) = \frac{1}{8^2} \sum_{i=1}^8 \sigma^2 = \frac{\sigma^2}{8} = \frac{2^2}{8} = \frac{1}{2} \end{aligned}$$

$$\begin{aligned} P(1467 < \bar{X} < 1469) &= P(\bar{X} \leq 1469) - P(\bar{X} \leq 1467) \\ &= P\left(\frac{\bar{X} - 1468}{\sqrt{\frac{1}{2}}} \leq \frac{1469 - 1468}{\sqrt{\frac{1}{2}}}\right) - P\left(\frac{\bar{X} - 1468}{\sqrt{\frac{1}{2}}} \leq \frac{1467 - 1468}{\sqrt{\frac{1}{2}}}\right) \\ &= P(Z \leq \sqrt{2}) - P(Z \leq -\sqrt{2}) = \Phi(1.41) - \Phi(-1.41) \\ &= 0.9207 - 0.0793 = \underline{\underline{0.84}} \end{aligned}$$

Vi skal i resten av oppgaven anta at forventningsverdien til legeringens smeltepunkt,  $\mu$ , er ukjent, men at standardavvik er kjent og lik  $\sigma = 2^\circ\text{C}$ .

- b) Utleid et 90% konfidensintervall for  $\mu$  basert på  $n$  uavhengige målinger av smeltepunktet,  $X_1, X_2, \dots, X_n$ .

Her er  $\sigma$  kjent og vi baserer oss på at

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

er standard normalfordelt.

Her lar vi  $\alpha = 0.1$  for å få et  $(1 - \alpha)100\% = 90\%$  konfidensintervall.

$$\begin{aligned} P\left(-z_{\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{\frac{\alpha}{2}}\right) &= 1 - \alpha \\ P\left(-z_{\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{\frac{\alpha}{2}}\right) &= 1 - \alpha \\ P\left(\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) &= 1 - \alpha \\ P(\hat{\mu}_L \leq \mu \leq \hat{\mu}_U) &= 1 - \alpha \end{aligned}$$

Lengden til intervallet er gitt som

$$\begin{aligned} L &= \hat{\mu}_U - \hat{\mu}_L = \left(\bar{X} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) - \left(\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) \\ &= 2 \cdot z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \end{aligned}$$

Vi observerer at lengden av intervallet ikke er stokastisk når  $\sigma$  er kjent.

Vi skal finne minste  $n$  slik at lengden på intervallet ikke overstiger  $3^\circ\text{C}$ .

$$\begin{aligned} L &\leq 3 \\ 2 \cdot z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} &\leq 3 \\ n &\geq \left(2 \cdot z_{\frac{\alpha}{2}} \frac{\sigma}{3}\right)^2 \end{aligned}$$

Innsatt  $z_{\frac{\alpha}{2}} = z_{0.05} = 1.645$  og  $\sigma = 2$  får vi

$$n \geq \left(2 \cdot 1.645 \cdot \frac{2}{3}\right)^2 = 4.8$$

Det minste antall observasjoner som gir et intervall med lengde som ikke overskrider  $3^{\circ}\text{C}$  er  $n_0 = 5$ .

Vi bruker de  $n_0 = 5$  første observasjonene gitt i tabellen i oppgaveteksten til å bestemme intervallt numerisk. Finner at  $\bar{x} = \frac{1}{5} \sum_{i=1}^5 x_i = 1468.88$ .

$$\hat{\mu}_L = \frac{\bar{x} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n_0}}}{\frac{\sigma}{\sqrt{n_0}}} = 1467.41$$

$$\hat{\mu}_U = \frac{\bar{x} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n_0}}}{\frac{\sigma}{\sqrt{n_0}}} = 1470.35$$

Som kvalitetsjekk observerer vi at lengden på intervallt da er  $1470.35 - 1467.41 = 2.94$  som er mindre enn 3.

c) Vi lar metallurgens lange erfaring med legeringens smeltepunkt være den konservative hypotesen, nullhypotesen, som Professor Stål forsøker å bestride. Professor Ståls angrep blir da den alternative hypotesen.

Vi kaller  $\mu_0 = 1468^{\circ}\text{C}$ , og får følgende hypoteser:

$$H_0 : \mu = \mu_0 \quad \text{vs.} \quad H_1 : \mu > \mu_0$$

Vi bruker  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  som estimator for  $\mu$  og vi vil forkaste  $H_0$  når  $\bar{X}$  er stor (fordi da tror vi på den alternative hypotesen). Vi vet at under  $H_0$  så er

$$Z_0 = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

standard normalfordelt. Hvis vi skal forkaste  $H_0$  når  $\bar{X}$  er stor, vil vi også forkaste  $H_0$  når  $Z_0$  er stor og vi bestemmer oss for å forkaste  $H_0$  når  $Z_0 > k$  ( $Z_0$  er dermed testobservatoren vår). Videre bestemmer vi  $k$  slik at

$$P(\text{type I feil}) = P(\text{forkaste } H_0 | H_0 \text{ er sann}) \leq \alpha.$$

Innsatt  $Z_0 > k$  for hendelsen “forkaste  $H_0$ ” og  $\mu_0$  for hendelsen “ $H_0$  sann”:

$$P(\text{forkaste } H_0 | H_0 \text{ er sann}) \leq \alpha$$

$$P(Z_0 > k | \mu_0) \leq \alpha$$

$$P\left(\frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} > k | \mu_0\right) \leq \alpha$$

Tallet  $k$  som har areal  $\alpha$  til høyre i standard normalfordelingen er kvantilen  $z_\alpha$ , dvs.  $k = z_\alpha$ . Dvs. vi forkaster  $H_0$  når

$$Z_0 = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} > z_\alpha$$

For  $\alpha = 0.05$  er  $z_{0.05} = 1.645$ . Videre har vi  $z_0 = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{1469.0 - 1468}{\frac{2}{\sqrt{n}}} = 1.41$ , som er mindre enn 1.645 og dermed gir det *ikke* forkastning. Konklusjonen er at det vi har observert (eller noe verre) er ganske sannsynlig (har høyere sannsynlighet enn 0.05) når  $H_0$  er sann, og vi forkaster dermed ikke  $H_0$ .

Nå vil vi se hvor lett det er å forkaste  $H_0$  med regelen vår hvis i virkeligheten  $\mu = 1470$ . Denne sannsynligheten er avhengig av vårt valgte signifikansnivå og hvor mange observasjoner vi har brukt til å lage testen vår (vi har et større forkastingsområde når vi har mange observasjoner). Vi skal finne et minimum antall observasjoner,  $n$ , slik at

$P(\text{Forkaste } H_0 | H_0 \text{ er gal og i virkeligheten } \mu = 1470) \geq 0.99$ . Utfordringen vår er nå at  $Z_0$  ikke lenger er standard normalfordelt (siden  $\mu_0$  ikke er den riktige forventningen), slik at vi må bruke at  $Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$  innsatt  $\mu = 1470$  er standard normalfordelt.

$$P(\text{Forkaste } H_0 | H_0 \text{ gal og i virkeligheten } \mu = 1470) \geq 0.99$$

$$P(Z_0 > z_\alpha | \mu = 1470) \geq 0.99$$

$$P\left(\frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} > z_\alpha | \mu = 1470\right) \geq 0.99$$

$$P(\bar{X} > \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}} | \mu = 1470) \geq 0.99$$

$$P\left(\frac{\bar{X} - 1470}{\frac{\sigma}{\sqrt{n}}} > \frac{\mu_0 - 1470}{\frac{\sigma}{\sqrt{n}}} + z_\alpha | \mu = 1470\right) \geq 0.99$$

Når  $\mu = 1470$  er  $\frac{\bar{X} - 1470}{\frac{\sigma}{\sqrt{n}}}$  i ligningen over standard normalfordelt, og vi kan matche  $\frac{\mu_0 - 1470}{\frac{\sigma}{\sqrt{n}}} + z_\alpha$  med kvantilen i standard normalfordelingen som har areal 0.99 til høyre for seg (siden det står  $>$  i ulikheten). Areal 0.99 til høyre har  $-z_{0.01}$  kvantilen. Vi setter inn for  $\mu_0 = 1468$ ,  $\sigma = 2$  og  $\alpha = 0.05$ , slik at vi fokuserer på at det er kun  $n$  som er ukjent. I første overgangen har vi delt på et negativt tall og må snu ulikhetsregnet.

$$\frac{1468 - 1470}{\frac{2}{\sqrt{n}}} + z_{0.05} \leq -z_{0.01}$$

$$\sqrt{n} \geq \frac{-(z_{0.01} + z_{0.05}) \cdot 2}{1468 - 1470}$$

$$n \geq \left(\frac{-(z_{0.01} + z_{0.05}) \cdot 2}{1468 - 1470}\right)^2$$

$$n \geq \left(\frac{-(2.326 + 1.645) \cdot 2}{1468 - 1470}\right)^2 = 15.77$$

Det minste antallet observasjoner som gir styrke 0.99 i alternativet  $\mu = 1470$  er  $n = 16$  observasjoner.

**Oppgave 2** Ventetid på snekerjentester

- a) Sannsynligheten for at ventetiden er lenger enn 2 uker:

$$P(X > 2) = 1 - P(X \leq 2) = 1 - F(2) = 1 - (1 - \exp(-0.04 \cdot 2^2)) = \exp(-0.16) = \underline{\underline{0.8521}}.$$

Sannsynligheten for at du må vente minst 5 uker, gitt at du må vente i minst 2 uker:

$$\begin{aligned} P(X > 5 | X > 2) &= \frac{P(X > 5 \cap X > 2)}{P(X > 2)} = \frac{P(X > 5)}{P(X > 2)} = \frac{1 - P(X \leq 5)}{1 - F(5)} \\ &= \frac{1 - \exp(-0.04 \cdot 5^2)}{1 - \exp(-0.04 \cdot 2^2)} = \frac{0.3679}{0.8521} = \underline{\underline{0.4317}}. \end{aligned}$$

Sannsynlighetstettheten til  $X$  for  $x \geq 0$  finner vi ved å derivere  $F(x)$ :

$$f(x) = \frac{dF(x)}{dx} = 0 - (-2\alpha x \exp(-\alpha x^2)) = 2\alpha x \exp(-\alpha x^2), \quad \text{for } x \geq 0.$$

- b) SME for  $\alpha$ :

Finner først rimelighetstettheten, som er simultanfordelingen for  $X_1, X_2, \dots, X_n$  sett på som funksjon av  $x_i$  ene og  $\alpha$ :

$$\begin{aligned} L(x_1, x_2, \dots, x_n; \alpha) &= f(x_1, x_2, \dots, x_n; \alpha) = \prod_{i=1}^n f(x_i; \alpha) \\ &= \prod_{i=1}^n 2\alpha x_i \exp(-\alpha x_i^2) = 2^n \alpha^n \left( \prod_{i=1}^n x_i \right) \exp\left(-\alpha \sum_{i=1}^n x_i^2\right). \end{aligned}$$

Tar logaritmen:

$$l(x_1, x_2, \dots, x_n; \alpha) = \ln L(x_1, x_2, \dots, x_n; \alpha) = n \ln 2 + n \ln \alpha + \sum_{i=1}^n \ln x_i - \alpha \sum_{i=1}^n x_i^2.$$

Deriverer med hensyn på  $\alpha$  og setter lik 0:

$$\begin{aligned} \frac{\partial l(x_1, x_2, \dots, x_n; \alpha)}{\partial \alpha} &= 0 + \frac{n}{\alpha} + 0 - \sum_{i=1}^n x_i^2 = 0 \\ \frac{n}{\alpha} &= \sum_{i=1}^n x_i^2 \\ \alpha &= \frac{n}{\sum_{i=1}^n x_i^2}. \end{aligned}$$

Dvs. SME for  $\alpha$  er  $\alpha^* = \frac{n}{\sum_{i=1}^n x_i^2}$ , som er ulik  $\hat{\alpha}$ .  $\hat{\alpha}$  er dermed ikke SME for  $\alpha$ .

$$\text{Estimator } \hat{\mu} \text{ for } \mu: \hat{\mu} = \frac{\sqrt{\pi}}{2\sqrt{\hat{\alpha}}} = \frac{\sqrt{\pi} \sqrt{\sum_{i=1}^n X_i^2}}{2(n-1)}.$$

$$\text{Innsatt verdier blir } \hat{\alpha} = 0.029 \text{ og estimatet for } \mu \text{ blir } \hat{\mu} = \frac{\sqrt{\pi}}{2\sqrt{\hat{\alpha}}} = \frac{\sqrt{\pi}}{2\sqrt{0.029}} = 5.2 \text{ uker.}$$

- c) Sannsynlighetsfordelingen for  $Y = X^2$  finner vi ved å bruke transformasjonsformelen.

La  $Y = u(X) = X^2$  slik at  $X = w(Y) = \sqrt{Y}$  (har at  $X > 0$ ). Dermed er

$$f_Y(y) = f_X(w(y)) |w'(y)| = 2\alpha \sqrt{y} \exp(-\alpha(\sqrt{y})^2) \left| \frac{1}{2\sqrt{y}} \right| = \alpha \exp(-\alpha y).$$

Dette er sannsynlighetstettheten i eksponensialfordelingen med forventning  $1/\alpha$ , og dermed har vi vist at  $Y$  er eksponensialfordelt.

Forventningsverdi for  $\hat{\alpha}$ :

$$E(\hat{\alpha}) = E\left(\frac{n-1}{\sum_{i=1}^n X_i^2}\right) = (n-1) \cdot E\left(\frac{1}{\sum_{i=1}^n X_i^2}\right) = (n-1) \cdot \frac{1}{(1/\alpha)(n-1)} = \frac{n-1}{n-1} \alpha = \alpha.$$

Her har vi brukt resultatet oppgitt i oppgaveteksten.

Siden  $E(\hat{\alpha}) = \alpha$ , er  $\hat{\alpha}$  forventningsrett.

**Oppgave 3** Ulykker

- a) Vi har at  $X_i$  er Poisson-fordelt med  $E(X_i) = a_i \lambda$ . I Poisson-fordelingen er også  $\text{Var}(X_i) = a_i \lambda$ .

Forventningsverdien til de to estimatorene  $\hat{\lambda}$  og  $\hat{\Lambda}^*$

$$\begin{aligned} E(\hat{\lambda}) &= \frac{1}{n} \sum_{i=1}^n \frac{1}{a_i} E(X_i) = \frac{1}{n} \sum_{i=1}^n \frac{1}{a_i} a_i \lambda = \frac{1}{n} \cdot n \cdot \lambda = \underline{\underline{\lambda}} \\ E(\hat{\Lambda}^*) &= \frac{\sum_{i=1}^n E(X_i)}{\sum_{i=1}^n a_i} = \frac{\sum_{i=1}^n a_i \lambda}{\sum_{i=1}^n a_i} = \lambda \cdot \frac{\sum_{i=1}^n a_i}{\sum_{i=1}^n a_i} = \underline{\underline{\lambda}} \end{aligned}$$

Variansen til de to estimatorene  $\hat{\lambda}$  og  $\Lambda^*$

$$\begin{aligned}\text{Var}(\hat{\lambda}) &= \frac{1}{n^2} \sum_{i=1}^n \frac{1}{a_i^2} \text{Var}(X_i) = \frac{1}{n^2} \sum_{i=1}^n \frac{1}{a_i^2} a_i \lambda = \lambda \cdot \frac{1}{n^2} \cdot \sum_{i=1}^n \frac{1}{a_i} \\ \text{Var}(\Lambda^*) &= \frac{\sum_{i=1}^n \text{Var}(X_i)}{(\sum_{i=1}^n a_i)^2} = \frac{\sum_{i=1}^n a_i \lambda}{(\sum_{i=1}^n a_i)^2} = \lambda \cdot \frac{1}{\sum_{i=1}^n a_i}\end{aligned}$$

Numeriske verdier for  $\hat{\lambda}$  og  $\Lambda^*$  fra data i tabell 2.

$$\begin{aligned}\hat{\lambda} &= \frac{1}{5} \sum_{i=1}^5 \frac{x_i}{a_i} = \frac{1}{5} \cdot 4.33 \cdot 10^{-5} = \underline{\underline{8.67 \cdot 10^{-6}}} \\ \Lambda^* &= \frac{\sum_{i=1}^5 x_i}{\sum_{i=1}^5 a_i} = \frac{8}{9.0 \cdot 10^5} = \underline{\underline{8.89 \cdot 10^{-6}}}\end{aligned}$$

Hvilken av de to estimatorene ville du foretrekke i denne situasjonen? Begge estimatorene er forventningsrette, men de har ulik varians. Numerisk varians (på konstant nær pga. at  $\lambda$  er ukjent):

$$\begin{aligned}\text{Var}(\hat{\lambda}) &= \lambda \cdot \frac{1}{n^2} \cdot \sum_{i=1}^n \frac{1}{a_i} = 1.63 \cdot 10^{-6} \cdot \lambda \\ \text{Var}(\Lambda^*) &= \lambda \cdot \frac{1}{\sum_{i=1}^n a_i} = 1.11 \cdot 10^{-6} \cdot \lambda\end{aligned}$$

Begge estimatorene er forventningsrette, men estimatoren  $\Lambda^*$  har minst varians. Derfor så foretrekker vi  $\Lambda^*$ .

b) Fordelingen til  $Y$  er den betingede fordelingen til  $X$  gitt at  $X \geq 1$  (minst én stor ulykke). Vi benytter i utledningen at  $X$  er Poisson-fordelt med punktsannsynlighet

$$P(X = x) = \frac{(a\lambda)^x e^{-a\lambda}}{x!}.$$

Dermed har vi:

$$\begin{aligned}P(Y = y) &= P(X = y | X \geq 1) = \frac{P(X = y \cap X \geq 1)}{P(X \geq 1)} = \frac{P(X = y)}{1 - P(X = 0)} \\ &= \frac{\frac{(a\lambda)^y e^{-a\lambda}}{y!}}{1 - \frac{(a\lambda)^0 e^{-a\lambda}}{0!}} = \frac{(a\lambda)^y}{y!} \cdot \frac{e^{-a\lambda}}{1 - e^{-a\lambda}}\end{aligned}$$

som skulle vises.

Forventningsverdien til  $Y$  finner vi fra  $E(Y) = \sum_{y=1}^{\infty} y \cdot P(Y = y)$ , innsatt  $P(Y = y)$ .

$$\begin{aligned}E(Y) &= \sum_{y=1}^{\infty} y \cdot P(Y = y) = \sum_{y=1}^{\infty} y \cdot \frac{(a\lambda)^y}{y!} \cdot \frac{e^{-a\lambda}}{1 - e^{-a\lambda}} \\ &= \sum_{y=1}^{\infty} \frac{(a\lambda)^y}{(y-1)!} \cdot \frac{e^{-a\lambda}}{1 - e^{-a\lambda}} = \sum_{z=0}^{\infty} \frac{(a\lambda)^{z+1}}{z!} \cdot \frac{e^{-a\lambda}}{1 - e^{-a\lambda}} \\ &= \frac{a\lambda}{1 - e^{-a\lambda}} \sum_{z=0}^{\infty} \frac{(a\lambda)^z}{z!} e^{-a\lambda} = \frac{a\lambda}{1 - e^{-a\lambda}} \cdot 1 = \frac{a\lambda}{1 - e^{-a\lambda}}\end{aligned}$$

Skiftet av sum fra  $y = (1, \infty)$  til  $z = y - 1$  der  $z = (0, \infty)$  er for å få  $\sum_{z=0}^{\infty} \frac{(a\lambda)^z}{z!} e^{-a\lambda} = 1$  siden dette er sum over alle punktsannsynligheter i en Poisson-fordeling med forventning  $a\lambda$ .