



LØSNINGSFORSLAG TIL EKSAMEN I FAG TMA4245 STATISTIKK
Lørdag 11.juni 2005

Oppgave 1 Meningsmålinger

a) Antagelser for at X er binomisk fordelt:

- Gjør n forsøk: Spør n personer.
- Registrerer suksess eller fiasko i hvert forsøk: Får svaret JA eller ikke JA (nei eller vet ikke) i hvert forsøk.
- $P(\text{suksess})$ lik i alle forsøk: Sannsynlighet for JA er p for alle som blir spurt.
- Forsøkene er uavhengige: Rimelig å anta at de som blir spurt svarer uavhengig av hverandre.

$$P(X \geq 18) = 1 - P(X < 18) = 1 - P(X \leq 17) \stackrel{\text{tabell}}{=} 1 - 0.965 = 0.035.$$

$$P(10 < X < 15) = P(X \leq 14) - P(X \leq 10) \stackrel{\text{tabell}}{=} 0.584 - 0.048 = 0.536$$

- b)
- $E(\hat{P}) = p$ og $\text{Var}(\hat{P}) = \frac{1}{4}(\frac{1}{n_1} + \frac{1}{n_2})p(1-p)$.
 - $E(P^*) = p$ og $\text{Var}(P^*) = \frac{1}{n_1+n_2}p(1-p)$.

Egenskaper for god estimator: forventningsrett og liten varians. Begge estimatorene er forventningsrette, men P^* har minst varians, vi velger derfor P^* .

La $\alpha = 0.05$. Siden $\frac{\hat{P}-p}{\sqrt{\frac{1}{2n}\hat{P}(1-\hat{P})}}$ er tilnærmet standardnormalfordelt får vi:

$$P\left(-z_{\frac{\alpha}{2}} < \frac{\hat{P}-p}{\sqrt{\frac{1}{2n}\hat{P}(1-\hat{P})}} < z_{\frac{\alpha}{2}}\right) \approx 1-\alpha$$
$$P\left(\hat{P} - z_{\frac{\alpha}{2}}\sqrt{\frac{1}{2n}\hat{P}(1-\hat{P})} < p < \hat{P} + z_{\frac{\alpha}{2}}\sqrt{\frac{1}{2n}\hat{P}(1-\hat{P})}\right) \approx 1-\alpha$$

Et tilnærmet 95% konfidensintervall for p blir da:

$$\left[\hat{p} - z_{0.025} \sqrt{\frac{1}{2n} \hat{p}(1 - \hat{p})}, \hat{p} + z_{0.025} \sqrt{\frac{1}{2n} \hat{p}(1 - \hat{p})} \right].$$

c) Vi har at

$$Y = X_3 - n\hat{P} = X_3 - n \frac{X_1 + X_2}{2n} = X_3 - \frac{1}{2}X_1 - \frac{1}{2}X_2.$$

Siden n er stor og p ikke nær 0 og 1, vil vi ha at $np > 5$ og $n(1-p) > 5$, slik at vi kan bruke normaltilnærming til binomisk fordeling. Vi kan dermed anta at X_1 , X_2 og X_3 alle er tilnærmet normalfordelt, de er uavhengige, og lineærkombinasjonen Y er dermed også tilnærmet normalfordelt.

$$\text{Var}(Y) = \text{Var}(X_3 - n\hat{P}) \stackrel{\text{uavh.}}{=} \text{Var}(X_3) + n^2 \text{Var}(\hat{P}) \stackrel{b)}{=} np(1-p) + n^2 \frac{1}{2n} p(1-p) = \frac{3}{2} np(1-p).$$

Har da at

- $X_3 - n\hat{P}$ er tilnærmet normalfordelt
- $\text{Var}(X_3 - n\hat{P}) = \frac{3}{2} np(1-p)$
- $E(X_3 - n\hat{P}) = E(X_3) - nE(\hat{P}) = np - np = 0$

Vi får da et prediksjonsintervall ved:

$$P \left(-z_{\frac{\alpha}{2}} < \frac{X_3 - n\hat{P}}{\sqrt{\frac{3}{2} np(1-p)}} < z_{\frac{\alpha}{2}} \right) \approx 1 - \alpha$$

$$P \left(n\hat{P} - z_{\frac{\alpha}{2}} \sqrt{\frac{3}{2} np(1-p)} < X_3 < n\hat{P} + z_{\frac{\alpha}{2}} \sqrt{\frac{3}{2} np(1-p)} \right) \approx 1 - \alpha$$

Siden n er stor, vil variansen til \hat{P} være liten, og \hat{P} være en god estimator for p . Vi kan derfor erstatte p med estimatet \hat{p} i uttrykket for intervallgrensene.

$$\text{Intervallet blir: } [n\hat{p} - z_{0.025} \sqrt{\frac{3}{2} n\hat{p}(1 - \hat{p})}, n\hat{p} + z_{0.025} \sqrt{\frac{3}{2} n\hat{p}(1 - \hat{p})}]$$

Innsatt verdier blir intervallet $[633, 704]$.

Oppgave 2 Veiprosjektet

- a) Vi jobber med X som er normalfordelt med forventning $\mu = 10000$ kr/meter og standardavvik $\sigma = 2500$ kr/meter.

$$\begin{aligned}
P(X > 13000) &= 1 - P(X \leq 13000) = 1 - P\left(\frac{X - 10000}{2500} \leq \frac{13000 - 10000}{2500}\right) = 1 - P(Z \leq 1.2) \\
&= 1 - \Phi(1.2) = 1 - 0.8848 = \underline{\underline{0.1152}}
\end{aligned}$$

Finn et tall, k , slik at sannsynligheten er 0.05 for at kostnaden pr. meter for veien vil bli mindre enn k .

$$\begin{aligned}
P(X < k) &= 0.05 \\
P\left(\frac{X - 10000}{2500} < \frac{k - 10000}{2500}\right) &= 0.05 \\
\frac{k - 10000}{2500} &= -1.645 \\
k &= -1.645 \cdot 2500 + 10000 = \underline{\underline{5887.5}}
\end{aligned}$$

Gitt at vi vet at kostnaden pr. meter blir minst 10000 kr/meter, hva er da sannsynligheten for at kostnaden pr. meter blir høyere enn 13000 kr/meter?

$$\begin{aligned}
P(X > 13000 | X > 10000) &= \frac{P(X > 13000 \cap X > 10000)}{P(X > 10000)} \\
&= \frac{P(X > 13000)}{P(X > 10000)} = 2 \cdot 0.1152 = 0.23
\end{aligned}$$

b) Null- og alternativ hypotese:

$$H_0 : \mu = 10000 \quad H_1 : \mu > 10000$$

De ukjente parameterene er μ og σ^2 , og vi setter opp følgende estimatorer:

$$\begin{aligned}
\hat{\mu} &= \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\
S^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2
\end{aligned}$$

Vi vet at under H_0 så er

$$T_0 = \frac{(\bar{X} - 10000)}{S \cdot \sqrt{\frac{1}{n}}} \quad t\text{-fordelt med } (n-1) \text{ frihetsgrader.}$$

Vi vil forkaste H_0 når $T_0 \geq k$, der konstanten k finnes slik at Type-I feilen er kontrollert på nivå α .

$$\begin{aligned} P(T_0 \geq k | H_0 \text{ sann}) &\leq \alpha \\ k &\leq t_{\alpha, (n-1)} \end{aligned}$$

der $t_{\alpha, (n-1)}$ er α -kvantilen i en t -fordeling med $n - 1$ frihetsgrader.

Forkastningsmråde: Forkast H_0 når $T_0 \geq t_{\alpha, (n-1)}$.

Når $\alpha = 0.01$ og $n = 9$ er $t_{0.01, 8} = 2.896$. Innsatt data fra tabell 1 i oppgaveteksten har vi:

$$\begin{aligned} \bar{x} &= \frac{106480}{9} = 11831.11 \\ s^2 &= \frac{1}{8} \sum_{i=1}^9 (x_i - \bar{x})^2 = \frac{49295335}{8} = 6161917 \\ s &= \sqrt{6161917} = 2482.3 \\ t_0 &= \frac{11831.11 - 10000}{\frac{2482.3}{\sqrt{9}}} = 2.21 \end{aligned}$$

Siden $t_0 = 2.21 < t_{0.01, 8} = 2.896$ så forkaster vi ikke H_0 på nivå $\alpha = 0.01$, og konkluderer med at vi har ikke tilstrekkelig bevis til å anta at kostnadene blir større enn 10000 kr pr. meter.

Når vi ikke forkastet H_0 på nivå 0.01 så betyr det at p -verdien må være større enn 0.01. P -verdien er gitt som

$$P(T_0 > t_0 | H_0 \text{ sann}) = P(T_0 > 2.21 | \mu = 10000) = 1 - P(T_0 \leq 2.21 | \mu = 10000)$$

der T_0 under H_0 er t -fordelt med $n - 1$ frihetsgrader. Fra tabell 2 i oppgaven så slår vi opp på $P(T \leq t)$ med $t = 2.2$ og $\nu = 8$, og finner 0.971, som gir p -verdi $1 - 0.071 = \underline{\underline{0.029}}$.

c) La $g(x)$ være sannsynlighetstettheten til X , og $h(y)$ være sannsynlighetstettheten til Y .

Siden X og Y er uavhengige, er simultan sannsynlighetstetthet $f(x, y) = g(x) \cdot h(y)$.

Forventingen til $W = X \cdot Y$:

$$\begin{aligned} E(W) &= E(X \cdot Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x \cdot y \cdot g(x) \cdot h(y) dx dy \\ &= \int_{-\infty}^{\infty} x \cdot g(x) dx \cdot \int_{-\infty}^{\infty} y \cdot h(y) dy = E(X) \cdot E(Y) = \mu \cdot \eta \end{aligned}$$

Alternativt: $\text{Cov}(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y) = 0$ når X og Y er uavhengige, slik at $E(W) = E(X \cdot Y) = E(X) \cdot E(Y) = \mu \cdot \eta$.

Før vi begynner på variansen, trenger vi følgende sammenhenger:

$$\begin{aligned} E(W^2) &= E(X^2 \cdot Y^2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^2 \cdot y^2 \cdot g(x) \cdot h(y) dx dy \\ &= \int_{-\infty}^{\infty} x^2 \cdot g(x) dx \cdot \int_{-\infty}^{\infty} y^2 \cdot h(y) dy = E(X^2) \cdot E(Y^2) \end{aligned}$$

$$\begin{aligned} \text{Var}(X) &= E[(X - \mu)^2] = E(X^2) - E(X)^2 = E(X^2) - \mu^2 \\ E(X^2) &= \text{Var}(X) + \mu^2 = \sigma^2 + \mu^2 \\ E(Y^2) &= \text{Var}(Y) + \eta^2 = \tau^2 + \eta^2 \end{aligned}$$

Variansen til $W = X \cdot Y$:

$$\begin{aligned} \text{Var}(W) &= E(W^2) - [E(W)]^2 = E(X^2) \cdot E(Y^2) - [E(X) \cdot E(Y)]^2 \\ &= (\sigma^2 + \mu^2) \cdot (\tau^2 + \eta^2) - [\mu \cdot \eta]^2 \\ &= \sigma^2 \cdot \tau^2 + \sigma^2 \cdot \eta^2 + \tau^2 \cdot \mu^2 + \mu^2 \cdot \eta^2 - \mu^2 \cdot \eta^2 \\ &= \sigma^2 \cdot \tau^2 + \sigma^2 \cdot \eta^2 + \tau^2 \cdot \mu^2 \end{aligned}$$

Oppgave 3 Kalibrering ved regresjon

- a) Y_i , $i = 1, \dots, m$ er uavhengige normalfordelte variabler, dermed er den lineære kombinasjonen \bar{Y} også normalfordelt. Siden $E[\bar{Y}] = E[Y] = \alpha$ ($x = 0$) og $\text{Var}(\bar{Y}) = \text{Var}(Y)/m = \sigma^2/m$, blir fordelingen til \bar{Y} lik $n(\cdot; \alpha, \sigma/\sqrt{m})$.

Har sett at $E[\bar{Y}] = \alpha$, så \bar{Y} er en forventningsrett estimator for α . Siden $\text{Var}(\bar{Y}) = \sigma^2/m \rightarrow 0$ når $m \rightarrow \infty$, følger det at mer data gir skarpere estimat, som er et rimelig krav til en estimator.

- b) Ut fra betraktningen over, får vi følgende rimelighetsfunksjon (likelihood-funksjon)

$$L(\beta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(y_i - \alpha - \beta x_i)^2}{2\sigma^2}\right\}$$

Bestemmer estimatoren ut fra ligningen

$$\frac{\partial}{\partial \beta} \ln L(\beta) = \frac{\partial}{\partial \beta} \left(-n \ln(\sqrt{2\pi}\sigma) - \sum_{i=1}^n \frac{(y_i - \alpha - \beta x_i)^2}{2\sigma^2} \right) = 0$$

Det gir ligningen

$$\sum_{i=1}^n x_i(y_i - \alpha - \beta x_i) = 0$$

(og siden $\partial^2 \ln L(\beta) / \partial \beta^2 = -\sum_{i=1}^n x_i^2 < 0$ svarer løsningen til et maks.punkt).

Dermed blir punktestimatet for SME gitt ved

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i(y_i - \alpha)}{\sum_{i=1}^n x_i^2},$$

og SME blir

$$B = \frac{\sum_{i=1}^n x_i(Y_i - \alpha)}{\sum_{i=1}^n x_i^2}$$

Minste kvadraters estimator fås ved å bestemme den verdien for β som minimierer

$$\sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$$

som igjen gir ligningen

$$\sum_{i=1}^n x_i(y_i - \alpha - \beta x_i) = 0$$

dvs. den samme som ovenfor, og vi får samme esitmator som SME.