

Faglig kontakt under eksamen:

Turid Follestad (98 06 68 80/73 59 35 37) Hugo Hammer (45 21 01 84/73 59 77 74) Eirik Mo (41 10 66 33/73 55 02 39) Henning Omre (90 93 78 48/73 59 35 31)

## EKSAMEN I TMA4245 Statistikk

Torsdag 7. juni 2007 Tid: 09:00 – 13:00

Tillatte hjelpemidler:

Gult A5-ark med egne håndskrevne notater (stemplet ved Institutt for matematiske fag)

Tabeller og formler i statistikk (Tapir forlag)

K. Rottmann: Matematisk formelsamling

Kalkulator: HP30S

BOKMÅL

Sensur: 28. juni 2007

## Oppgave 1 Pengespillet

I et TV-program får et visst antall deltakere sjansen til å vinne et større pengebeløp. For hver deltaker består spillet av en serie påfølgende runder, der deltakeren i hver runde får presentert en oppgave. For hver oppgave deltakeren klarer, får han/hun et gitt beløp. Spillet avsluttes når deltakeren første gang ikke greier oppgaven, og deltakeren får da med seg beløpet vunnet i de øvrige rundene. Vi antar at ingen deltaker trekker seg frivillig underveis.

La p være sannsynligheten for IKKE å klare oppgaven i hver enkelt runde, og la videre X være antall runder for en tilfeldig valgt deltaker. Antall runder X defineres her slik at deltakeren går ut etter å ha klart oppgavene i de X-1 første rundene, men ikke oppgaven i runde X. Vi antar at sannsynligheten p er lik for hver runde og for hver deltaker, og at resultatene for hver runde er uavhengige.

I denne situasjonen er X geometrisk fordelt med parameter p, slik at punktsannsynligheten f(x;p) og den kumulative fordelingsfunksjonen  $F(x;p) = P(X \le x)$  for X er

$$f(x;p) = p(1-p)^{x-1}, x = 1, 2, ...$$
  
 $F(x;p) = 1 - (1-p)^x, x = 1, 2, ...$ 

a) Anta bare i dette punktet at p = 0.10.

Forklar hvorfor X er geometrisk fordelt med parameter p i denne situasjonen.

Beregn sannsynligheten for at deltakeren går ut i første runde.

Beregn sannsynligheten for at deltakeren er med i spillet når det er gått fem runder.

Hva er sannsynligheten for at han/hun kommer videre til niende runde men ikke klarer oppgaven i niende runde, gitt at deltakeren var med i spillet når det var gått fem runder?

Det viser seg at deltakerne jevnt over henger med lenger enn forventet, og det begynner å bli dyrt for TV-selskapet. De vil undersøke om de har feilvurdert vanskelighetsgraden, og vil beregne et anslag for p, som nå ansees som ukjent.

La  $X_1, X_2, \ldots, X_n$  være antall runder for hver av n tilfeldig valgte deltakere, der  $X_i$ ,  $i = 1, \ldots, n$  er uavhengige og geometrisk fordelte med samme parameter p.

b) Utled et uttrykk for sannsynlighetsmaksimeringsestimatoren (maximum likelihood estimator) for p basert på det tilfeldige utvalget.

Hva blir estimatet dersom n = 8, og antall runder for de 8 deltakerne er 4, 22, 9, 11, 15, 5, 26 og 17?

TV-selskapet bruker to personer, A og B, til å lage oppgavene. Selskapet ønsker å undersøke om vanskelighetsgraden er avhengig av hvem av dem som lager oppgavene.

De ser på resultatene fra  $n_1$  tilfeldig valgte deltakere som har oppgaver fra oppgavelager A, og  $n_2$  fra oppgavelager B. La  $Z_1$  og  $Z_2$  være antallet blant disse som klarer færre enn fem oppgaver fra henholdsvis oppgavelager A og B. Vi antar at  $Z_1$  og  $Z_2$  er uavhengige.

c) Forklar hvorfor  $Z_1$  og  $Z_2$  er binomisk fordelte med parametre  $(n_1, q_1)$  og  $(n_2, q_2)$ , der  $q_1$  og  $q_2$  er sannsynligheten for å klare færre enn fem oppgaver i de to gruppene.

Som estimatorer for  $q_1$  og  $q_2$  skal vi bruke

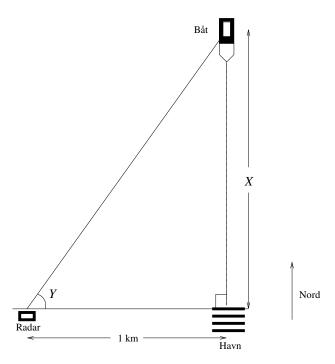
$$\hat{q_1} = \frac{Z_1}{n_1}$$
 og  $\hat{q_2} = \frac{Z_2}{n_2}$ .

Utled et tilnærmet 95% konfidensintervall for  $q_1 - q_2$  basert på normaltilnærming til binomisk fordeling. Beregn intervallet numerisk når  $n_1 = n_2 = 64$ , og observerte verdier for  $Z_1$  og  $Z_2$  er  $z_1 = 34$  og  $z_2 = 18$ .

Gir det estimerte konfidensintervallet TV-selskapet grunnlag for å si at oppgavene fra A og B har ulik vanskelighetsgrad? Begrunn svaret.

## Oppgave 2 Radar

En havneby observerer ankommende skip ved å bruke radar. Vi antar for enkelhets skyld at skipene alltid ankommer fra nord. Radaren er plassert 1 kilometer vest for havna. Det er ønskelig å oppdage ankommende skip så tidlig som mulig av praktiske og sikkerhetsmessige årsaker. Når skipet første gang fanges inn på radaren, observerer radaren vinkelen  $Y \in [0, \pi/2)$ ,



Figur 1: Illustrasjon til oppgave 2.

som vist i Figur 1. Radaren observerer kun vinkelen Y, og ikke avstanden til skipet. Vinkelen Y varierer fra skip til skip av mange årsaker.

La den kumulative fordelingsfunksjonen til Y være

$$F(y;\beta) = P(Y \le y) = \frac{1 - \exp\{-y/\beta\}}{1 - \exp\{-\pi/(2\beta)\}}, \quad y \in [0, \pi/2),$$

der  $\beta > 0$  er en parameter.

a) Anta bare i dette punktet at  $\beta = \pi/8$ .

Regn ut 
$$P\left(Y > \frac{\pi}{4}\right)$$
,  $P\left(\frac{\pi}{4} < Y < \frac{\pi}{3}\right)$  og  $P\left(Y > \frac{\pi}{4} \mid Y < \frac{\pi}{3}\right)$ .

b) Vis at sannsynlighetstettheten  $f(y;\beta)$  til Y er

$$f(y;\beta) = \frac{1}{\beta - \beta \exp\{-\pi/(2\beta)\}} \exp\{-y/\beta\}, \quad y \in [0, \pi/2).$$

Havnebyen er mer interessert i avstanden til havna når skipet først oppdages enn vinkelen Y som radaren observerer. La X betegne denne avstanden, som vist i Figur 1.

Utled et uttrykk for sannsynlighetstettheten til X.

Det oppgis at 
$$\frac{d}{dx}(\tan(x)) = \frac{1}{\cos^2(x)}$$
 og  $\frac{d}{dx}(\arctan(x)) = \frac{d}{dx}(\tan^{-1}(x)) = \frac{1}{1+x^2}$ .

## Oppgave 3 Ultralydavbildning med kontrastmiddel

En måte å oppdage tidlig utvikling av kreftceller i leveren på er å studere tettheten av blodkar. Mikroskopiske gassbobler tilsettes blodet, og sees ved å sende ultralyd mot forskjellige deler av leveren. Mange gassbobler et sted gir kraftig høyfrekvent (annenharmonisk) ekko, som indikerer mange blodkar og mulig kreft.

La  $Y_i$ , i = 1, ..., n være styrken på det høyfrekvente ekkoet i desibel  $(20 \log_{10} \text{ av amplituden})$  som apparatet registrerer for n målinger. Vi vil anta at målingene  $Y_i$  er uavhengige og identisk normalfordelte, med varians  $\sigma^2$ .

a) Anta bare i dette punktet at  $\sigma^2=0.01^2$  og at alle ekkodataene skaleres så forventningsverdien til  $Y_i$  er eksakt 1.0.

Regn ut sannsynligheten for at en enkelt ultralydmåling er større enn 1.0.

Regn ut sannsynligheten for at avviket i absoluttverdi fra 1.0 i en enkelt måling er større enn 0.02.

Hvis en tar to uavhengige målinger fra samme sted i leveren, hva er da sannsynligheten for at gjennomsnittet avviker i absoluttverdi mer enn 0.02 fra 1.0?

Absorbsjon og spredning gjør ultralydsignalet svakere fra punkter i leveren langt fra måleapparatet. Vi setter opp en lineær regresjonsmodell  $Y = \alpha + \beta x + E$ , med n par av målinger  $(x_i, Y_i)$ ,  $i = 1, \ldots, n$ , der  $Y_i$  er målt som før, og  $x_i$  er en kjent forklaringsvariabel basert på dybden i kroppen ekkoet kommer fra. Feilene  $E_i$  er uavhengig normalfordelte med forventningsverdi 0.0 og ukjent varians  $\sigma^2$ . Parametrene  $\alpha$  og  $\beta$  avhenger av fysiologien til pasienten, og er ukjente.

Vi vil bruke følgende estimatorer for  $\alpha$  og  $\beta$ :

$$A = \widehat{\alpha} = \overline{Y} - B\overline{x},$$

$$B = \widehat{\beta} = \frac{\sum_{i=1}^{n} (x_i - \overline{x}) Y_i}{\sum_{i=1}^{n} (x_i - \overline{x})^2},$$

der 
$$\bar{Y} = \frac{1}{n} \sum_{i=1}^{n} Y_i$$
 og  $\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$ .

Det oppgis at

$$E(B) = \beta$$
 og  $Var(B) = \frac{\sigma^2}{\sum_{i=1}^{n} (x_i - \bar{x})^2}$ .

**b)** Utled uttrykk for E(A), Var(A) og Cov(A, B).

Ta med mellomregning/omforminger du bruker for å komme fram til svarene på enkleste form og bruk uten bevis at B og  $\bar{Y}$  er uavhengige.

Sannsynlighetsmaksimeringsestimatoren (maximum likelihood estimator) for  $\sigma^2$  basert på n målinger med forskjellige  $x_i$  er

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - A - Bx_i)^2.$$

Metoden er på prøvestadiet og testes bare på friske testpersoner. For en frisk pasient, skal variansen ikke overstige  $0.01^2$ . (For disse pasientene er fordelingen av blodkar jevn/homogen, og variansen i målingene skyldes da bare tilfeldig variasjon i tettheten av gassbobler i blodet.) Hvis resultatet av n=30 uavhengige målinger på en testperson gir grunnlag for å forkaste hypotesen om at  $\sigma^2=0.01^2$  og hevde at  $\sigma^2>0.01^2$ , sendes testpersonen til en dyr kreftundersøkelse.

c) Utled et uttrykk for forventningsverdien til  $\tilde{\sigma}^2$ . Formulér problemstillingen over som en hypotesetest, og beregn kritisk område (forkastningsområde) for  $\tilde{\sigma}^2$  for testen. La signifikansnivået være 0.01.